LLM

Deep learning - Computer vision va
Large Languages Models uchun kaliti.

Supervised ML => Deep learning => Computer Vision
                                => LLMs.

Two leading LLMs

ChatGPT by OpenAI => GPT-6 Astra
                     GPT-6 Sol
                     GPT-6 Luna
                     GPT-6.1 Sol

Claude by Authropic => Claude Fable 5.1
                       Claude OPus 5.5
                       Claude Sonnet 5.5
                       Claude Haiku 5.5

Language models: (LMs).
U matnda keyingi so'z (token) ning bo'lishini taxmin qiladigan model.
(Input text) => [model] => [predicted next word]
=> Autocomplete, Grammer checks.

LLMs => Large Language models

Bu juda katta hajmdagi matn bilan o'gitilgan, milliardlab parametrga (weights) ega til modeli.

Massive datasets => Giant Neural Network => High performance Generation and reasoning

=> Chat, translate, answer questions.
=> GPT-6, Claude, Gemini

Token

LLM matnni o'qiydigan eng kichik bo'lak. U butun so'z, so'zning qismi yoki bitta belgi bo'lishi mumkin.

=> Model matnni to'g'ridan to'g'ri tushunmaydi, u faqat sonlar bilan ishlaydi. Shuning uchun matn avval tokenlarga bo'linadi va har bir bo'lak raqamga o'girilardi.

Tokenization types

1. Word tokenization:
=> Matn bo'sh joy bo'yicha so'zlarga bo'linadi.
"Men maktabga bordi."
["Men", "maktabga", "bordi", "."]

② Character tokenization.

=> Har bir belgi alohida token.

["M", "e", "n", ..., "b", "o", "r", "d", "i", "m"] => 19 token.

=> Lug'at juda kichik: alifbo + raqam + belgilar [UNK] deyarli chiqmaydi.

③ Byte tokenization

=> Avval matn UTF-8 baytlarga aylantiriladi. (har bir bayt 0-255 oralig'idagi son). Keyin har bir bayt token bo'ladi.

④ BPE (Byte pair Encoding)

Eng tez-tez yonma-yon keladigan juftlikni ditto tokenga birlashtirib boriladi.

matn => bor, bordim, boroli, borish

step1 => bu da 4 martta yonma-yon keldi. bo

step2 => bo va r 4 martta yonma-yon keldi: bor

step3 => ~~bord~~ du va i 2 martta => di.

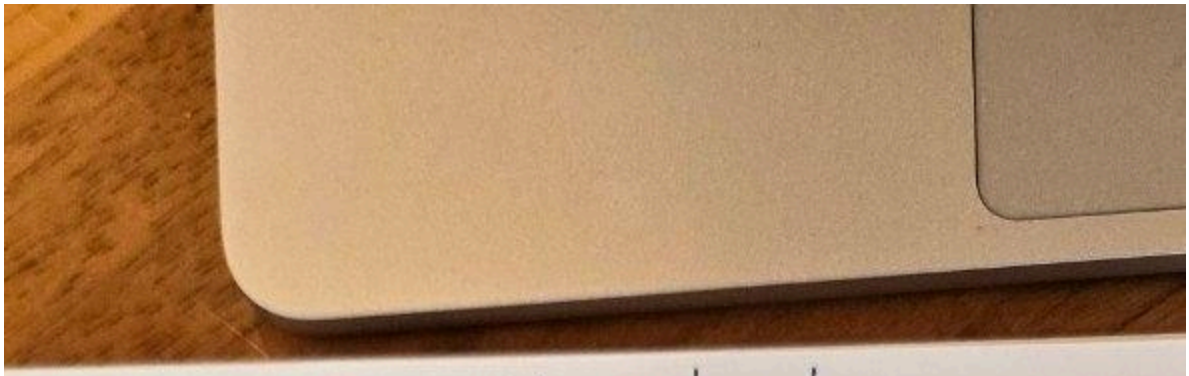
Natija: bor => [bor].

bordim => [bor, di, m].

boroli => [bor, oli].

borish => [bor, i, s, h].

=> O'zbekcha ko'rilmagan so'z kelsa ham bo'laklarga bo'linadi.



	word	character	byte	BPE
lug'at hajmi V	juda katta	kichik (~100)	256	30k-200k
ketma-ketlik	qisqa	uzun	eng uzun	o'rtacha
Yangi so'z	muammo	yo'q	yo'q	yo'q
Ishlatilishi	eski modellar	kam	BPE asos	GPT

(Frontier Modellar)

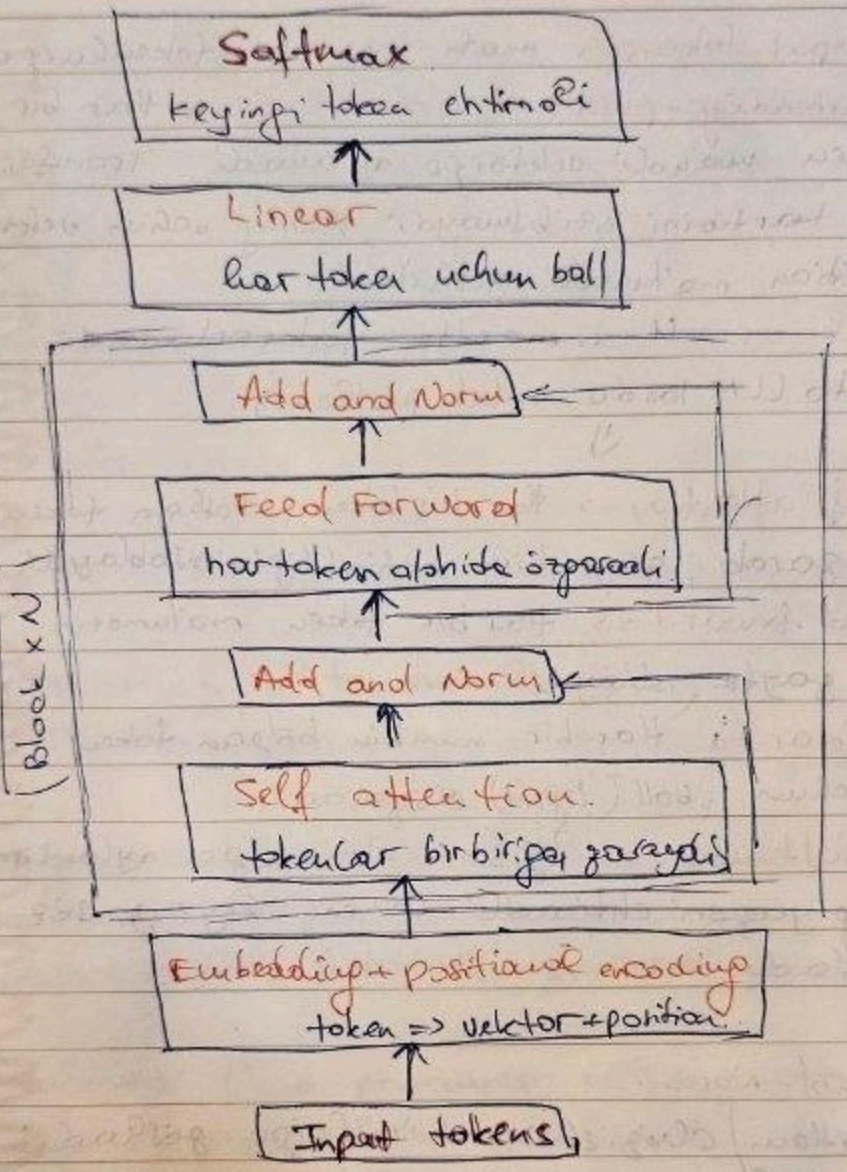
Eng oxirgi kuchli modellar. Ulkan compute clusterlarda boy kompaniyalar tomonidan o'qitiladi

GPT-4 => 1.8T parametr edi 5T marta o'qitish taxminan $100M+ turadi

Bizning maqsadda kichik miqyosda (millionlab parametrlar) LLM qurish va o'qitishni o'rganish. Bu kichik modellar orqali arxitekturani tushunib keyinchalik katta loyihalarni modellarini qurish.

(Small to Big)

The transformer heart of an LLM architecture



1. Input tokens => matn avval tokenlarga bo'linadi.
2. Embedding + positional Encoding => Har bir token ma'noli vektorga aylanadi. Transformer so'z tartibini sezibilmaydi, shuning uchun vektorga position ma'lumoti qo'shiladi.
3. Block => U n martta takrorlanadi. (katta LLM larda onlab qatlam)

⇓

Self attention => Har bir token boshqa tokenlarga qarab, qaysi biri muhimligini hisoblaydi.
Feed forward => Har bir token ma'lumotini qayta ishlaydi.

4. Linear => Har bir mumkin bo'lgan token uchun ball (logits) chiqaradi.
5. Softmax => logits ni ehtimolga aylantiradi. Eng yuqori ehtimolli token keyingi so'z bo'ladi.

Add and Norm:
↓ Qatlam chiqishini kiritilishga qo'shadi; o'qitishni osonlashtiradi.
Sonlarni bir xil masshtabga keltiradi.

FLOP => Floating Point Operation.

Kasr sonlar ustida bajariladigan bitta matematik amal. Neyron tarmog hisoblash narxini o'lchashning standart birligi.

=> LLM matn yaratish uchun juda ko'p matematik hisob kitoblar bajaradi. matrix, multiplication, addition shu amallar soni FLOPs bilan o'lchanadi.

FLOPs => Bajariladigan matematik amallar soni.

FLOPS => Bir sekundda bajariladigan amallar soni (tezlik).

1 TFLOP => 10^{12} ta amal.

1 TFLOPS => sekundiga 10^{12} ta amal bajarish tezligi.

Training => modelni o'rgatish uchun ancha hisoblash kerakligi.

Hardware => GPU hisoblash quvvati yetarliligini.

=> Modelda P ta parametr bo'lsa, bitta tokenni generatsiya qilish uchun taxminan

FLOPs $\approx 2P$

=> Agar 7 milliard parametr bo'lsa

$2 \times 7 \times 10^9 \Rightarrow$ 14 GFLOPs demak bitta token uchun 14 milliard floating point amal bajarilishi mumkin.

Training FLOPs ≈ 6ND

N => modeldagi parametrlar soni

D => training davomida model ko'rgan tokenlar soni

6 => har bir parametr uchun forward pass va backward pass hisob kitoblarini taxminiy ko'rsatgich sifatida qo'llanilgan koeffitsient.

7 milliard parametr, 1 trillion training token.

$N = 7 \cdot 10^9$, $D = 10^{12}$

$6ND = 6 \times 7 \times 10^9 \cdot 10^{12} = 4.2 \times 10^{22}$ FLOPs.

Demak, Training uchun $4,2 \times 10^{22}$ ta floating point amal kerak bo'ladi.

Emergence paydo bo'lish.

Modelda ma'lum bir kesim chegarasi dan o'tganda birdan paydo bo'layotgan qobiliyat. - aste-sekin emas, tasodifan. Kichik modellarda umuman yo'q, kattalarida birdaniga paydo bo'ladi.

1B parameters => oddiy matnni tushunadi.

10B parameters => murakkabroq savollarga javob bera oladi.

100B parameters => ayrim murakkab reasoning vazifalarni bajara oladi.

"The Bitter lesson"

=> Uzoq muddatda ko'proq computation va umumiy algoritm usullaridan foydalanadigan AI tizimlari, inson g'olda kiritgan bilimlarga asoslan tizimlardan ko'pincha ustun keladi.

1-usul: Maxsus AI ga qoidalarning barcha strategiyalarini g'olda kiritish.

2-usul: AI ga g'oidalarni berish, ko'p o'yin o'ynash va tajribadan o'rganish imkonini berish.

=> Ikkinchi usul ko'proq computation va training orqali kuchliroq natijaga erishish mumkin.

(Chinchilla law):

LLM ni optimal o'rgatish uchun model hajmi (parameters) va training data hajmi (tokens) munosabatini tanlash kerakligini o'rgatuvchi g'oida.

$D \approx 20N$

N => model parameters soni.
D => training tokens soni.

7 milliard parameters:

$D \approx 7 \cdot B \times 20 = 140$ B.

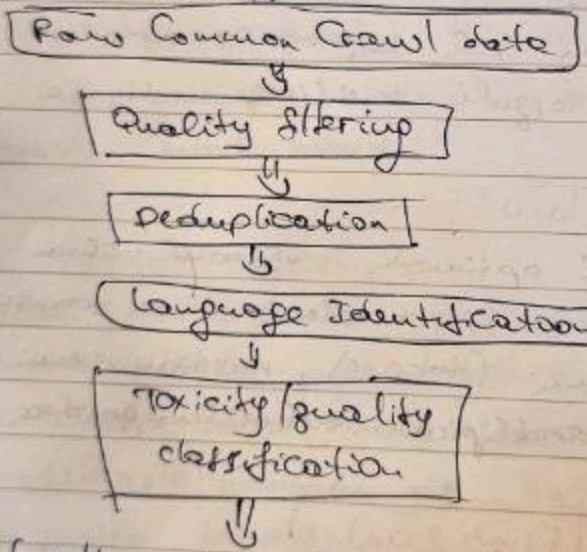
140 milliard training tokens.

Common Crawl

internetdagi milliardlab web sahifalarni yig'ib, ochiq dataset sifatida taqdim etadigan loyiha. LLM training uchun muhim.

Crawling => Extracting => Filtering => Training

=> Ma'lumot sifatini 2x. yaxshilash model hajmini 10x oshirishdan kura koproq natija berishi mum.



Cleaned, filtered high quality data.

Alignment: moslashuv.

Language modelni inson niyatlariga, foydali, zararsiz, va halol bo'lishiga yo'naltirish jarayoni.

=> Chatgpt, Claude - alignedlar. Ular "Bambo qanday yaratildi?" savoliga javob bermaydi.

Supervised Fine-tuning

Re-trained modelni (prompt, ideal javob) juftliklari, to'plami ustida o'qitish. Modelga foydalanuvchi savollariga javob berish formatini o'rgatadi.

RLHF => Reinforcement learning from Human Feedbacks

Model output orasidagi inson afzalliklaridan reward model o'qitiladi, so'ngra RL orqali LLM inson afzal ko'rgan chiqishlar berishi uchun yo'naltiriladigan o'qitilish usuli.

Pre-train => xom intellekt. ⟶ ChatGPT.
SFT => tarbiya.
RLHF => inson qiymatlariga moslashuv.

Eng yaxshi LLM yaratish
nimani o'rganamiz?

Data

Common crawl, books, Cleaning, deduplication, tokenization.

qanday o'rgatish?

Architecture

Transformer, Attention, layers, parameters, Tokenizer.

qancha data, compute kerak?

Scaling

Model size, Training tokens, GPU/TPU
Compute budget, Chinchilla law

qanday narsa bilan bu ishlarni tezlatamiz?

Efficiency

Mixed precision, Flash Attention, Quantization
Distributed training.

qanday foydali qilamiz, xatosini kamaytiramiz

Alignment

SFT, Preference optimization. (RLHF)
Safety, Human feedback.