Embedding

=> Tokenni ma'nosini ifodalaydigan sonlar ro'yxati (vektor)

=> Har bir so'zni xaritadagi nuqta deb tasavvur qilsak
cat va dog yaqin joyda (ikkalasi hayvon)
car va truck yaqin joyda (transport)
cat va car uzoq

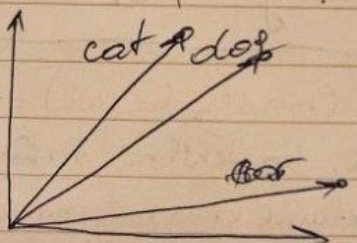
=> Nuqtaning koordinatalari → embedding vektor.

(3 o'lchamli misol).

(0-1) oralig'ida.

Savol:	Cat	Dog	Car
1. jonlimi?	0.9	0.8	0.1
2. mashinami?	0.1	0.2	0.9
3. Uyda bog'ladimi?	0.8	0.7	0.2

Embeddings:
Cat = [0.9, 0.1, 0.8]
dog = [0.8, 0.2, 0.7]
Car = [0.1, 0.9, 0.2]



Qiymatlar o'xshash bo'lsa, so'zlar o'xshash.

=> Bu qiymatlar nimani anglatishini model o'zi o'rganadi, har bir qiymat aniq bir ma'noni anglatmaydi ular aralash ma'noni anglatadi.

=> o'lchamlar katta bo'ladi.

Classical Encoding (One-hot Encoding).

=> Qattiy qoidalarga asoslangan konvertatsiya.
=> Insan tomonidan yozilgan formulalar orqali
=> Ma'no yo'q, unikal ID raqam.
=> Sparse vector [0, 0, 1, 1, 0]. (0 0 1)
=> Lug'at hajmi oshishi bu vektor hajmini kengayadi.

Learned Embedding (Modern LLMs).

=> Sun'iy neyron tarmoqlar tomonidan o'rganilgan usul.
=> Modelni katta matnlar to'plamida o'qitish orqali shakllanadi.
=> Chuqur ma'no bor. So'zlar orasidagi semantik bog'liqlik.
=> Dense vektor => Floating point [0.23, -0.15, 0.33]
=> Doimiy va cheklangan o'lchamda bo'ladi.
Odatda 3072, 4096 o'lcham.

Vektor => sonlar ro'yxati.
Sparse => ko'p nol, ma'nosiz, uzun.
Dense => to'liq sonlar, mazmunli, qisqa
Embedding => sparse dan dense ga o'tish.

Static (meaning based) => bitta so'z doimiy bitta vektor. kontekstni tushunmaydi.
Contextual (meaning-based) => Attension orqali so'z ragamlari gapga qarab o'zgaradi.
Token (structure based) => Tokenning faqat lug'aviy ma'nosini, tartibini bilmaydi.
Absolute Pos. (structure) => Har bir indexga o'z qatiy koordinata qo'shadi. (Fixed context).
Relative Pos (structure) => So'zlar orasidagi masofani o'lchaydi

RoPE (Rotary) - Structure based.

=> Vektorlarni burchakka aylantiradi; matn shuni aniq topadi.

ROPE => Rotary Positional Embedding

=> Tokenlar qayerda joylashgani.
=> Tokenlar bir biridan qancha uzoqlikda ekanini aniqlaydi.

Misollar: ALI VALINI ko'rdi.
VALI ALINI ko'rdi.

so'zlar bir xil, lekin tartibi boshqa.
ROPE tokenning o'rniga qarab uning Q va K vektorlarini matematik ravishda aylantiradi.

Attention

Model matndagi qaysi tokenlar bir biri bilan muhim bog'liqligini hisoblaydigan mexanizm.

=> Input Embeddings (Token + ROPE).
=> Ma'nosiz bog'lanmagan vectorlarni, mazali bog'langan so'zlarga aylantiruvchi mexanizm.
=> Manosiz vector -> manoli so'zlar (gaplar)
=> uzun textlarni ham tushunish, eslab qolish.

Embeddings => Mana so'zlar va ularning ma'nosi va joylashgan o'rni (position embeddings) ROPE) => Input

Attention => Ularni aralashtiradi, birgalikda barcha so'zlardan gap tuzadi (bir birige so'zlarni ~~bir-birlashtirib~~ qo'shib orqali ma'nosini topadi) => Action

Architectural Attention types

MHA -> Multi head Attention. - aniq, og'ir

MAQ -> Multi query Attention. - balans ✓

GQA -> Grouped Query Attention - tez aniq emas

Context Optimization Attention Types

Sparse

Sliding window.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Q - query

K - key

V - value

LLM

local

=> O'zimizning kompyuter/server (CPU/GPU) da ishlaydi.
=> Bir martalik narx. faqat GPU/uskuna narxi
=> Maxfiy
=> Internet kerak emas
=> Setup giyin
=> Llama 3/4, deepseek
=> Sifati o'rtacha. uskunaga bog'liq
=> Tezlik uskunaga bog'liq

claude based

Anthropicning cloud serverlarida ishlaydi
-> Doimiy, harbir so'rov uchun to'lov yoki oylik.
=> Maxfiy emas.
=> kerak.
=> Onlon
=> Claude Sonnet 5, Haiku 4.5
=> eng yuqori darajada.
=> odatda barqaror va tez.