1. Block foundations.
(Layers, Norms, Acts).

Feed Forward Layers (FFN) | Normalization. (LayerNorm, RMSNorm) | Activation Functions (GELU, SWIGLU)

Layers Matematik amallar yig'indisini inputni outputga weightlar yordamida o'tkazadi.

=> LLM NN da Layerlar 2 qismdan tashkil topgan va har biri uchun alohida nerfa mavjud.

① Attention Layer (Context Engine)
Tokenlar bir biri bilan gaplashadi va ular orasidagi bog'liqlikni hisoblaydi.

② Feed Forward Network (FFN) (Knowledge Engine)
Har bir token alohida ishlanadi

Attention Layer.

=> Gapdagi so'zlarni bir biri bilan bog'laydi va umumiy manoni aniqlaydi.

=> Global ishlaydi. Butun matnga, barcha so'zlarga birdek qaraydi.

=> M: Bir nechta odam yig'ilib, o'zaro fikr almashayotgani va vaziyatni muhokama qilayotgani.

=> Grammatika, sintaktis, so'zlar aro munosabat ni o'rganadi.

FFN layer

=> Har bir tokenni alohida qayta ishlaydi. Har bir tokenning o'zini mustaqil tahlil qilib, unga mantiq va faktlarni qo'llaydi.

=> Local ishlaydi. Faqat bitta so'zning tokenining vektoriga qaraydi, boshqalariga aralashmaydi.

=> M: Har bir odam alohida kamerada o'tirib ensiklopediyadan aniq bir faktni qidirayotgani.

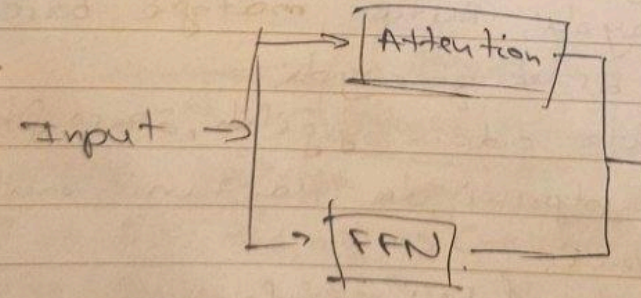
=> Dunyoqarash, aniq faktlar, mantiqiy fikrlash qobiliyatlari va ensiklopedik bilimlarni o'rganadi.

Layerlarning turli xil joylashtirish usullari bor. Serial va parallel.

Serial:

Input -> Attention -> FFN |o

Parallel:



(Normalization)

2 ta asosiy turi mavjud.

① LayerNorm:

*) Markazlashtiradi. o'rtachani ayiradi

=> Masshtablaydi standart og'ishga bo'ladi.

Mean, Variance.

=> Har safar GPU boshlanicha xotira evaziga mean va variance hisoblaydi.

② RMSNorm: Root Mean Square Normalization.

=> Har bir so'zni hisoblab o'rniga o'rta arifmetik va variance ni topish o'rniga bir so'zni o'zining o'rtacha kvadratik (RMS) ga bo'ladi.

=> Faqat o'lchovni tenglashtiradi.

soddaroq derrog.

$x = [2, 4, 6]$.

Qadam:	LayerNorm	RMSNorm
o'rtachani topish	4	kvadrat ildiz
o'rtachani ayirish	-2, 0, +2	kvadrat ildiz
kvadratlar o'rtachasi	2.667	18.667
Ildiz olish.	1.633.	4.320
Bo'lish	(-1.285, 0, 1.225)	(0.463, 0.926, 1.389)
Natija		

RMSNorm o'rta qadamni o'tkazib yuboradi.

Activation Functions

Linearity → Non Linearity

=> Input sifatida kirgan qaysi qiymat keyingi bosqichga o'tish yoki o'tolmasligi (holga tenglashishi) talab yuborilishi) kerakligini belgilab beradi

RELU: Neyronlarni o'chirib yuborgani uchun LLM da ishlatilmaydi.

GELU: Ilk transformerlarning asosi bo'lgan silliq funktsiya.

SWIGLU: Eng zo'r. Sanoat standarti. Eng tez.

GEGLU: SWIGLU kabi kuchli lekin biroz sekinroq.

Tokenization

— So'zlarni kichik qismlarga ajratish jarayoni

Vocabulary

— Ajratilgan qismlar to'plami.

② Tokenization - qaysi qismi qaysi ID ga mos kelishini belgilaydi.
"Girgitton" => "Gir", "git", "ton"

② Vocabulary - ajratilgan bo'laklarni o'zining ichki ro'yxatidan qidiradi va ularning ID raqamlarini qaytaradi.
"Gir" → ID: 250, "git" → ID: 430, "ton" → ID: 300.

Pre-Norm

Input => Tokenization => Normalization => Attention / FNN => Activation

Post-Norm

Input => Tokenization => Attention / FNN => Normalization => Activation

---

- Modellar juda uzun textlar bilan ishlaganda GPU xotirasi cache (KV key value xotira uborii) bilan to'lib ketadi. model sekinlashadi. -> GPU out of memory bo'ldi.

MHA - Multi Head Attention.

- Har bir attention head o'zining alohida Query (Q), key, (K), value (V) ma'lumotlariga ega.

Q (Query) - hozirgi token nimani izlayabdi.
K (key) - har bir token qanday ma'lumotni taklif qiladi
V (value) - tokenning uzatadigan ma'lumoti.
Attention - qaysi token ma'lumotiga qancha e'tibor berishini hisoblaydi.

Q - savol beradi, K moslikni aniqlashga yordam beradi, V - kerakli ma'lumotni beradi

Misol: 32ta attention head.

- Har bir head Q, K, V ga ega
  => Gapni turli tomondan tahlil giladigan 32ta mutaxassis bor.
  1-head ... , 2-head, ... , 32-head.
  => Har bir head uchun alohida K va V saqlanadi Uzun matnda KV cache katta bo'ladi.

MQA - Multi Query Attention

Endi 32ta head o'rniga barcha query headlar bitta umumiy K va V head dan foydalanadi.

Q -> 32ta
K -> 1ta
V -> 1ta

=> K va V uchun malumot kamroq saqlanadi. KV cashe kichrayadi.

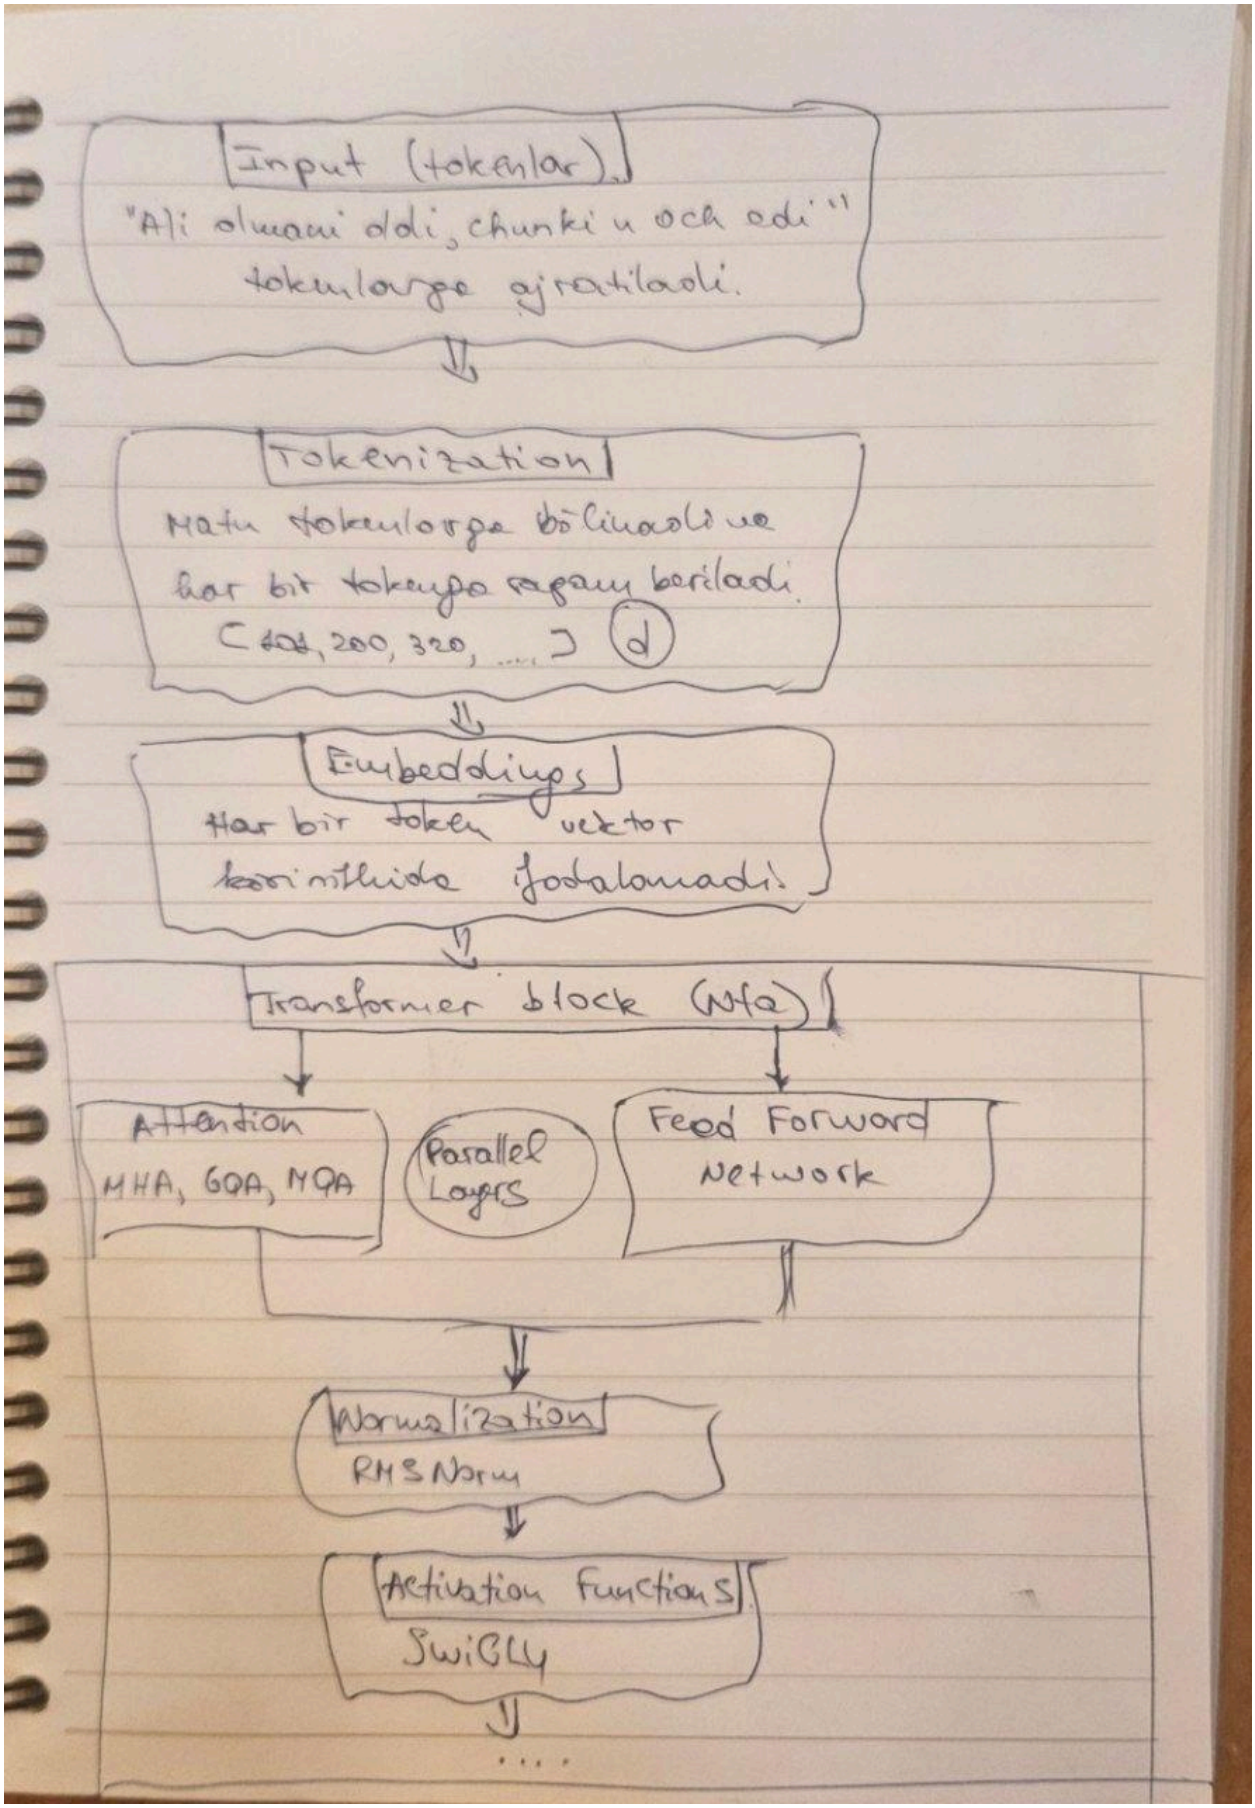
GQA - Grouped Query Attention

Endi: 32ta query headni 8ta guruhga bo'lamiz.

- Har bir guruhda 4ta query head bor
  ular 1ta K/V headdan foydalanadi.

Q -> 32ta
K -> 8ta
V -> 8ta

=> MHA dan kamroq xotira, lekin MQA dan ko'proq K/V headlar saqlaydi.


Input (tokenlar)
"Ali olmani ddi, chunki u och odi"
tokenlarga ajratiladi.
Tokenization
Matn tokenlarga bo'linadi va
har bir tokenga raqam beriladi.
[408, 200, 320, ...] d
Embeddings
Har bir token vektor
koordinatlida ifodalanadi.
Transformer block (Nta)
Attention
MHA, GQA, MQA
Parallel Layers
Feed Forward
Network
Normalization
RMS Norm
Activation Functions
SwiGLU
...