Training va Performance

Architecture tayyor bo'lgandan so'ng training tez, arzon va xatoliklarsiz bo'lishi kerak.
3 ta qismdan iborat:

① Hyperparameters

Parameter – (weight) model o'zi o'rganadigan sonlar.
Hyperparameter – biz trainingdan oldin o'zimiz qolda tanlaydigan sozlamalar. Model ularni o'rganmaydi.

M: Non yopishda xamirning tarkibi (parameter) pishirish jarayonida shakllanadi. Pechning harorati, vaqti (hyperparameters) esa o'zimiz belgilaymiz

Learning rate

Har bir yangilanishdagi qadam kattaligi.

M: Tepadan pastga tushyapmiz (loss kamaymoqda). Gradient yo'nalishini ko'rsatadi, lr esa har bir qadam uzunligi.

$10^{-4} - 3\,10^{-4}$ => Frontie modell experience

juda kichik bo'lsa: o'qitish juda sekin vaqt va pul ketadi.

juda katta bo'lsa: optimal yechim o'rgasib yuboriladi.

Learning rate schedule

Bu butun o'qitish davomida bir xil turmaydi. Ikki bosqich bo'ladi.

A: Warmup - Boshida oz-ozdan boshlanib asta-sekin maksimumga ko'tariladi.

B: Decay - Maksimumdan jonli asta-sekin kamayadi. Cosine decay

Global batch size

Bitta optimizer stepda (bitta parameter yangilanishida) hamma GPU lar birgalikda ko'radigan misollarning jami soni.

=> LLAMA 3 va GPT-4 o'qitilishida 1M dan 4M + tokenpacha (millionlab so'zlar bir soniyada).

Per device batch size

Bitta qurilma (GPU) bir martta forward/backward qiladigan misollar soni.

Global = Per device x GPU soni

Optimizer — AdamW

Parameterlarni qanday yangilashni hal qiladi,
=> U har bir parameter uchun 2ta narsani eslab qoladi,

m - oxirgi gradientlarning o'rtachasi, ya'ni yo'nalish.
v - gradient kvadratlarining o'rtachasi, ya'ni gradient qanchalik katta yoki shovqinli ekani.

Qadam = yo'nalish / kattalik. Gradient katta bo'lsa qadam kichraytiriladi. kichik bo'lsa kattalashtiriladi.

Gradient clipping

Ba'zan gradient juda katta bo'lib ketadi. (exploding gradient). Bitta shunday step weight larni butkul buzib yuboradi, loss sakraydi yoki NaN

Yechim: Gradientning umumiy uzunligi chegaradan oshsa uni kichraytiramiz

Llama va Gemini max-norm => 1.

Weight decay

Har bir qadamda weightlarni nolga tomon ozgina tortish.
→ weightlar juda katta bolib ketmasin, model malumotlarni yoddab olmasligi.

jarima

standart qiymat (0.1)

LLM da faqat weight decay yetarli dropout=0.0

Post Norm => Pre Norm.

- Pre-Norm da Gradient chuqur qatlamlardan bemalol orqaga qaytadi Post-Norm da gradient har layerda Normdan otadi.

Layer Norm => RMS Norm

- Hisob kam va parameter kam.
2ta hisob kitobni olgotib yuborarkan.

y=wx+b => y=wx nobias

- Bias parameterlari juda kam.
Sifatga deyarli ta'sir qilmaydi.
Xotira ogirligi va yozilishi biroz kamaytiradi

ReLU / GeLU => SwiGLU / GeGLU

- Gate vazifasini bajaradi. Ikkinchisidan qancha ma'lumot olishni hal giladi. Model nimani o'tkazishini o'zi tanlay oladi.

Absolute => ROPE

Har bir pozitsiyaga alohida vektor.

Q vak vektorlari pozitsiyaga qarab burchakka ay/aytiradi

Model, "kim qayerda" emas "kim kimdan qancha uzoqda" ni ko'radi

- Absolute ko'rilmagan uzun pozitsiyalarda yomon ishlaydi.

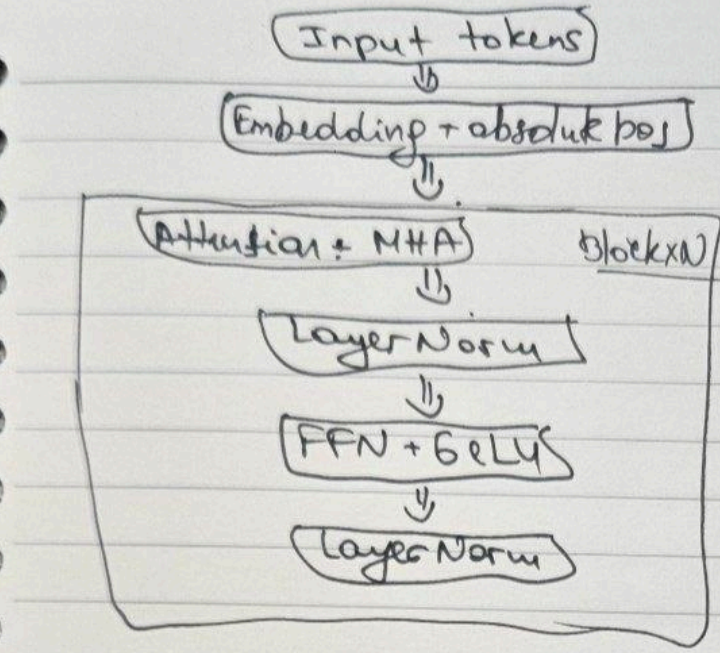
MHA => GQA

Har bir head Q, K, V

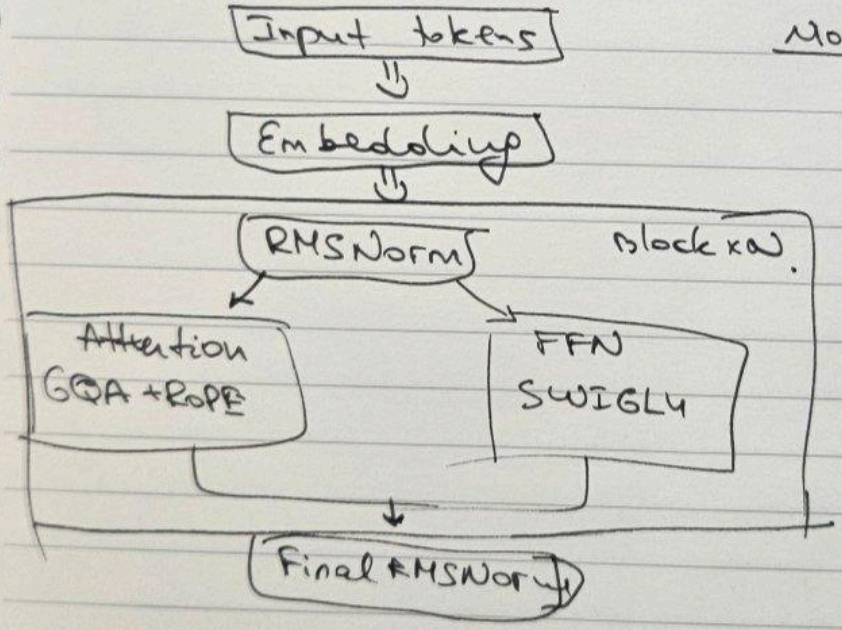
→ ko'p Q lar kamroq K, V,

K, V cache ↓

old


Input tokens
Embedding + absolute pos
Attention + MHA
Block xN
LayerNorm
FFN + GeLU
LayerNorm

Modern


Input tokens
Embedding
RMSNorm
Block xN
Attention
GQA + RoPE
FFN
SWIGLU
Final RMSNorm