Tokenization - matnni model qayta ishlay oladigan kichik birliklar, ya'ni tokenlarga ajratish jarayoni.

Masalan: modelga "odam kitob o'qidi" jumlasi berilsa, tokenizer ushbu matnni tokenlarga ajratadi. Har bir token vocab ichidagi ma'lum bir ID b-n ifodalanadi

- Tokenlar hardoim ham to'liq so'zlardan iborat bo'lmaydi. so'zning bir qismi yoki

Embedding - tokenni sonli vector ko'rinishida ifodalash usuli. Vector - bir nechta sonlardan tashkil topgan ro'yxat

Masalan: token ID: 15. Embedding layer ushbu ID uchun o'rganilgan vector qaytaradi. [0,2, 0,5, -0,4, ...]

Nima uchun kerak? Chunki Transformer Attention layer token IDlarining o'zidan emas, balki vector ko'rinishidagi ifodalardan foydalanadi.

Embedding vectoridagi har bir sonning alohida va aniq ma'nosi bo'lmaydi. Har bir sonda ma'lum bir ma'no bo'ladi!

Embedding 2ta turi bor.

Positional embedding

Matndagi so'zlarning tartibi muhim.

- Odam kitob o'qidi.
- Kitob o'qidi odam.

So'zlarning tartibi farq qilyabdi.

=> Shu sababli model tokenning o'zini ifodalashi b-n birga uning ketma-ketlikdagi o'rniga oid ma'lumotni ham hisobga olishi k-k.

(WPE -> word position embedding)

(wte -> word token embedding)

Attention - modelga ketma-ketlikdagi tokenlar o'rtasidagi bog'liqliklarni hisobga olish imkonini beradigan mexanizm.

=> Attention tokenlar o'rtasidagi muhim aloqalarni o'rganishga yordam beradi. Bu jarayonda embedding vectorlari muhim rol o'ynaydi. (Attentionga vector k-k)

① Transformers kutubxonasini yuklab olamiz. Bu kutubxona Hugging face (AI uchun github) tomonidan ishlab chiqilgan python kutubxona tayyor AI modellarni yuklab olib ishlatish va fine-tune qilish imkonini beradi.

Hugging face ga kirib ~~m~~modellarni o'rganishimiz m-n. Qanday tokenize qilgan, embedding qanday qilingan va hokazo.

- tokenize qismini ishlatish uchun shunchaki ~~[illegible]~~ tokenizer qismini yuklab olish kifoya.

- embeddingsni ko'rish uchun esa to'liq modelni yuklab olishimiz kerak.

- yuklangan filelar .cache ga tushadi. Har safar qayta qayta yuklanavermaydi.

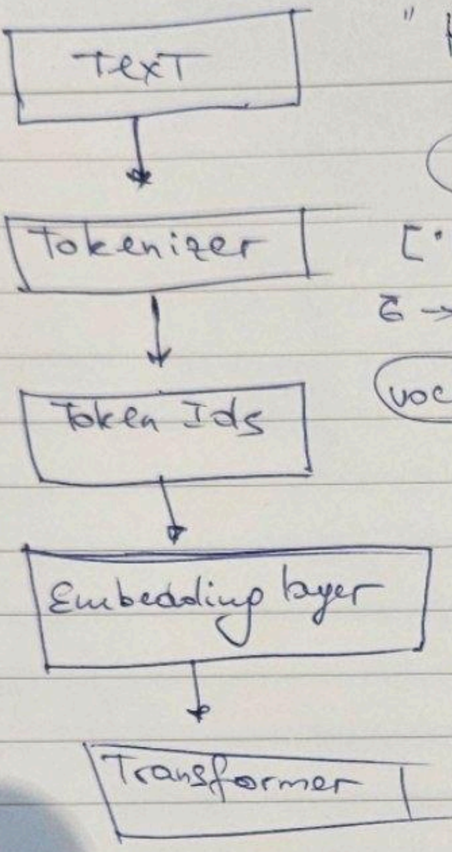
TexT
Tokenizer
Token Ids
Embedding layer
Transformer

" Hello world "

GPt2

["Hello", ĠWorld]

Ġ -> bosh joyni anglatadi.

vocab

"Hello" => 25
"Ġworld" => 70.

"Hello" -> [0.5, 0.4, -0.3, ..., -0.7].
"Ġworld" -> [0.3, 0.288, ..., -0.33].
bularning uzunligi
d => dimension

. . .