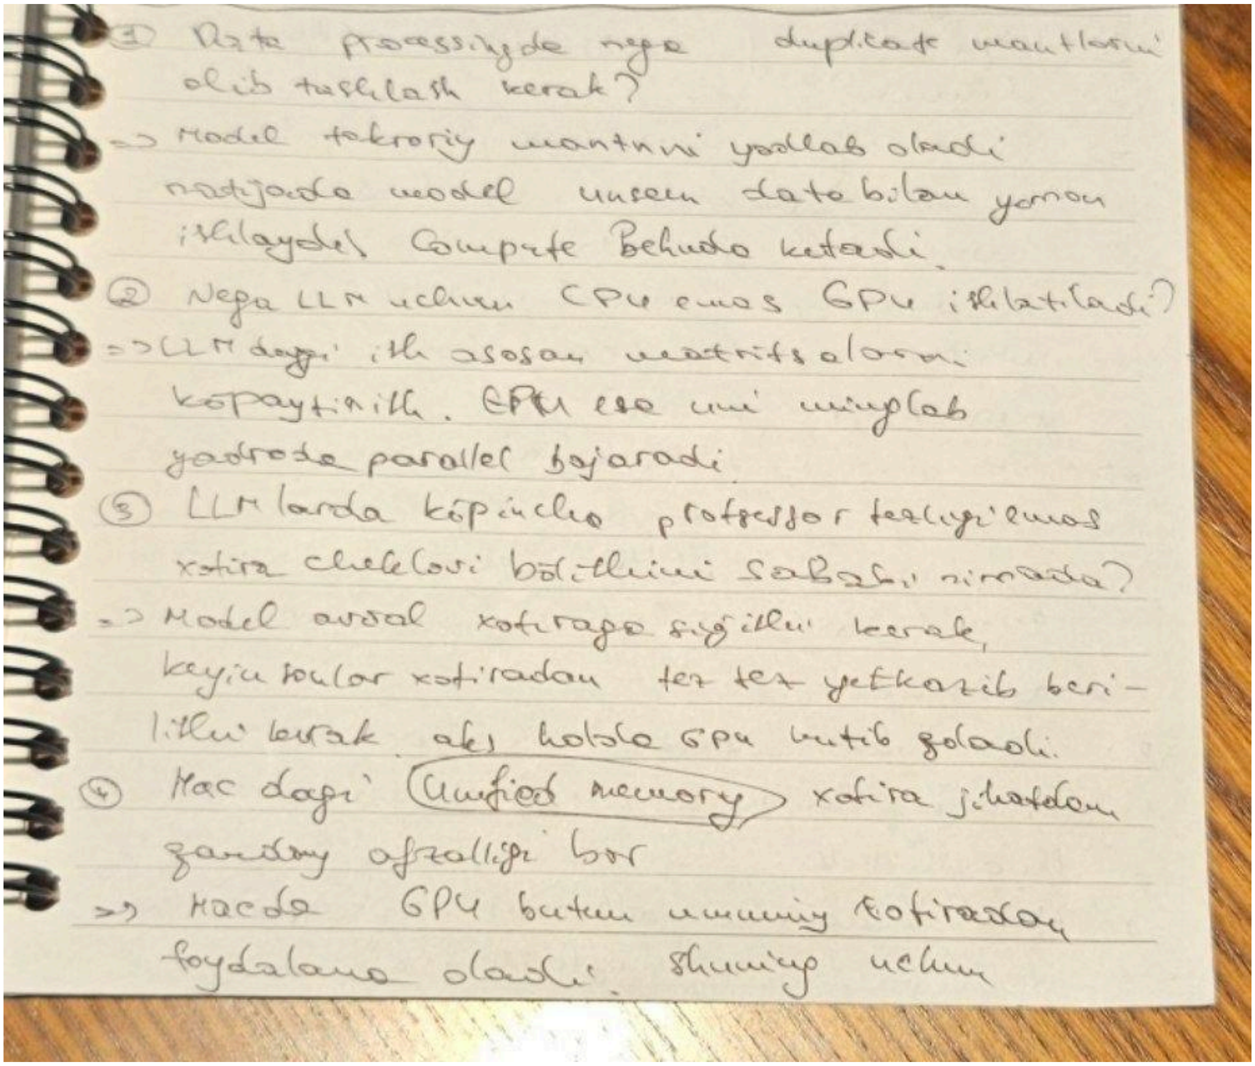

① Data processingda nega duplicate matnlarni olib tashlash kerak?

=> Model takroriy matnni yodlab oladi natijada model unseen data bilan yomon ishlaydi Compute behuda ketadi.

② Nega LLM uchun CPU emas GPU ishlatiladi?

=> LLM dagi ish asosan matritsalarni kopaytirish. GPU esa uni minglab yadroda parallel bajaradi.

③ LLMlarda kópincha protsessor tezligi emas xotira cheklovi bölishini sababi nimada?

=> Model avval xotiraga sig'ishi kerak, keyin sonlar xotiradan tez tez yetkazib berilishi kerak aks holda GPU kutib qoladi.

④ Mac dagi Unified memory xotira jihatdan qanday afzalligi bor

=> Macda GPU butun umumiy xotiradan foydalana oladi. Shuning uchun katta modelni sig'dirib ishlaroq.

Mac (Apple M chip)

CPU GPU

unified memory (RAM).

⑤ Base model savolga javob bermay, matnni davom ettiradi. Bu nima uchun shunday bōladi.

=> Pretraining maqsadi faqat matnni davom ettirish. Internetda savollardan keyin javob emas, boshqa savollar keladi; shuning uchun model ham shunday davom ettiradi.

⑥ Nega bilimning asosiy qismi pretrainingda olinadi?

=> Pretrainingda trillionlab token kōriladi. SFT da juda kam data bōladi, u faqat javob berish formatini ōrgatadi.

⑦ SFT dan keyin model allaqachon savollarga javob bera oladi. Nega yana RLHF kerak?

=> SFT faqat 1ta tōg'ri javobni kōrsata oladi, qaysi javob yaxshiroq ekanini ōrgatmaydi. RLHF javoblarni solishtirib model xatti harakatini yanada nozik sozlaydi.

⑧ Nega modelni faqat ōqitilgan data ustida emas, kōrmagan data ustida baholash k-k.

=> Model shunchaki yodlamasdan, haqiqatdan ōrganganini aniqlash uchun.

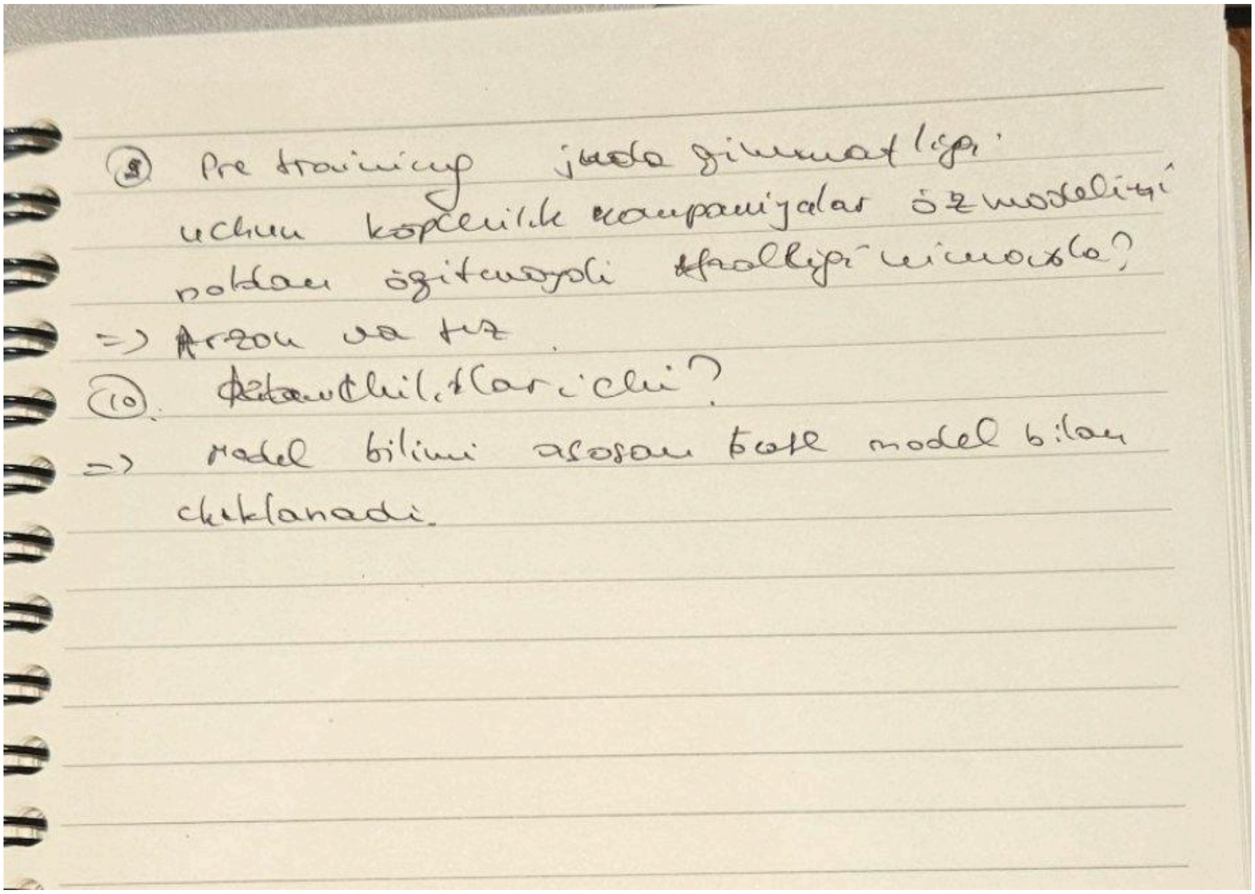

⑨ Pre training juda qimmatligi uchun köpchilik kompaniyalar öz modelini noldan ögitmaydi. Afzalligi nimada?

=> Arzon va tez.

⑩. Cheklovlari chi?

=> model bilimi asosan base model bilan cheklanadi.