⑨ Pre training juda qimmatligi uchun ko'pchilik kompaniyalar öz modelini noldan o'qitmaydi farqligi nimada?
=> Arzon va tez
⑩ Cheklovlari nima?
=> Model bilimi asosan base model bilan cheklanadi.

Gitignore

→ Githubga push qilinmaydigan fayllar ro'yxati
→ API keylar (private datalar bo'lsa), datasets, model weights kabilarni githubga chiqarmasligimiz kerak. Shu sabab gitignore dan foydalanamiz.

Supervised ML da

- (File) hajmlari kichik bo'ladi, bir necha megabytes. Agar to'g'ridan gitga push qilib yuborsak, Git uni osonlik bilan handle qila oladi
- (Datasetlar) tez tez o'zgarib (tracked) qilinadi team bilan ishlanayotganda
- Agar model kichik chiqsa (publicga chiqarish kerak) financial cost past bo'ladi, chunki uni train qilish (minutes) ketadi (CPU).

Large language Models

- Fayl hajmi juda katta, tens of gigabytes. Tarqatishda push qilish bir qancha muammolarga olib keladi.
- Datasets raw text crawls Terabytes bo'ladi. Barligi serverlarda storagelarda saqlanishi kerak. (AWS, Huggingface)..
- Agar LLM base weights chiqib ketib qolsa, Raqobatchilar o'g'irlashi mumkin. Millionlab dollarlar ketgan bo'ladi.

Data sources

LLM faqat datadan o'rganadi. Shuning uchun data qayerdan olinganligi model nimani bilishini belgilaydi. Pretraining uchun data sources

=> web sahifalar: Common Crawl, Fine Web
-> kitoblar : ochiq kitoblar to'plami.
=> Ensiklopediya: Vikipedia
=> Coding : Github, Stack

Common crawl => Internetni muntazam skanerlab chiqadigan ochiq loyiha. U juda katta lekin "trash"; reklama, spam va duplicated text.
Buning tozalangani => FineWeb

Deduplication: (Takrorlarni olib tashlash)
=> Bir xil yoki juda öxshash matnlarni
olib tashlaydi. Aks holda (memorization)

PII / privacy (Shaxsiy malumotlar)
=> PII => Personally identifiable Information.
Insonni aniqlash mumkin bölgan malumotlar
Telefon raqam, manzil, email, passport raqam
öchiriladi yoki maskalanadi.

Final corpus: Barcha tekshiruvlardan ötgan,
öqitishga tayyor toza data.

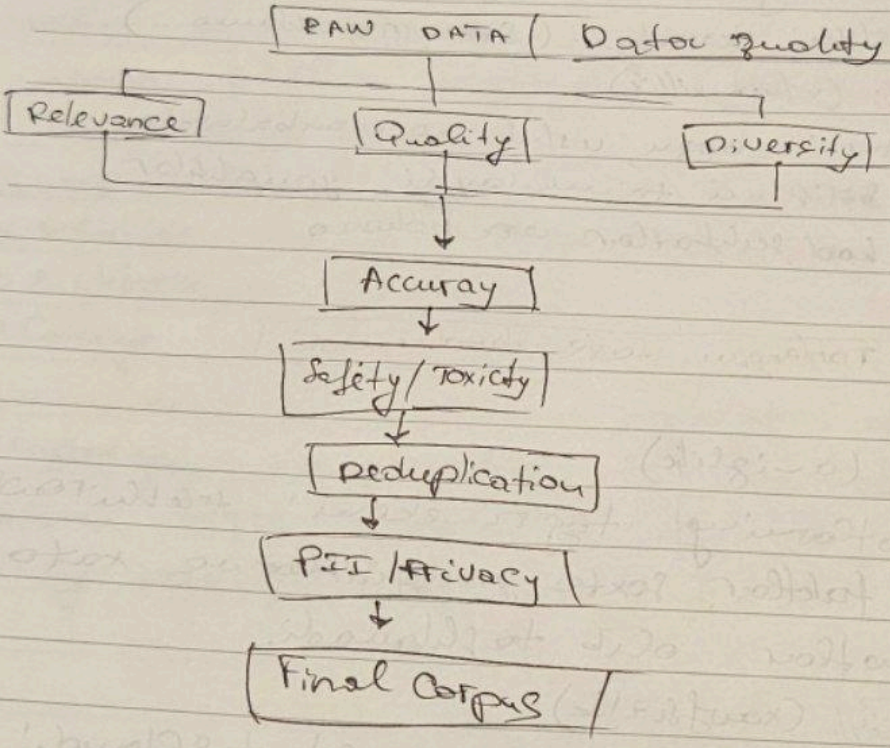

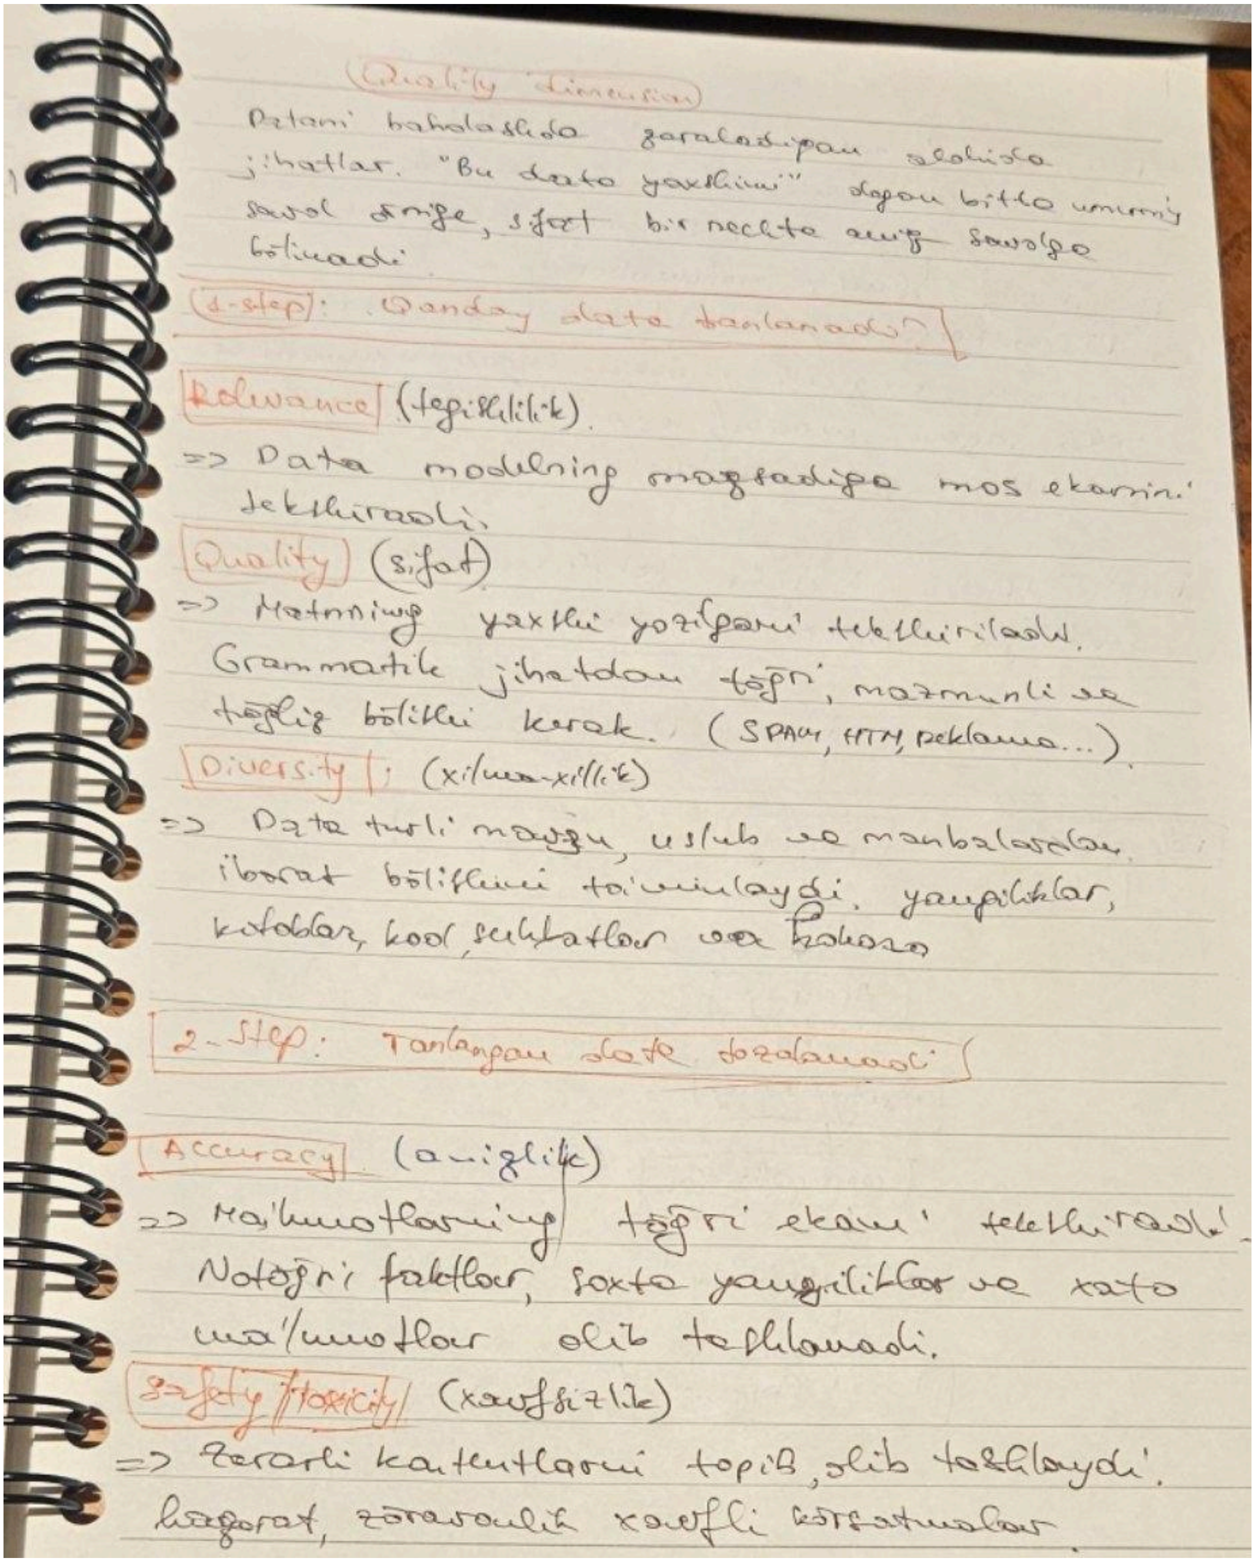

Quality Dimension

Datani baholashda qaraladigan alohida jihatlar. "Bu data yaxshimi" degan bitta umumiy savol örniga, sifat bir nechta aniq savolga bölinadi

1-step: Qanday data tanlanadi?

Relevance (tegishlilik).

=> Data modelning maqsadiga mos ekanini tekshiradi.

Quality (sifat)

=> Matnning yaxshi yozilgani tekshiriladi. Grammatik jihatdan tögri, mazmunli va töliq bölishi kerak. (SPAM, HTM, reklama...).

Diversity: (xilma-xillik)

=> Data turli mavzu, uslub va manbalardan iborat bölishini ta'minlaydi. yangiliklar, kitoblar, kod, suhbatlar va hokazo

2-step: Tanlangan data tozalanadi

Accuracy (aniqlik)

=> Ma'lumotlarning tögri ekani tekshiriladi. Notögri faktlar, soxta yangiliklar va xato ma'lumotlar olib tashlanadi.

Safety / Toxicity (xavfsizlik)

=> Zararli kontentlarni topib, olib tashlaydi. haqorat, zöravonlik xavfli körsatmalar.

Data mixture:

Data qaysi manbalardan, qanday nisbatda olinishi. Ya'ni turli data turlarining ~~nisbati~~ "retsepti".
web => 60%, code => 20%, books => 10%, vikipedia => 10%
Nisbatlarni o'zimiz tanlaymiz. (Random emas)

License

Muallif hoqlarga beradigan foydalanish ruxsati va uning shartlari.

- Internetda open source degani ishlatish uchun ruxsat degani emas. Har bir open sourcening muallifi bor va uni ishlatish uchun ruxsat kerak bo'lishi mumkin.

=> Data yoki modeldan qanday foydalanish mumkinligini belgilaydigan ruxsat.

Model litsenziyasi ikki shaklda yoziladi; kompyuter o'qishi uchun YAML metadata va odam o'qishi uchun Data Lineage va Licensing Notice.

YAML ->

datasets -> qaysi data bilan o'qitilgan?
license -> litsenziya. (turi)
tags -> Model nima qiladi?
-> Bu qismni sayt avtomatik o'qiydi litsenziyani belgi qilib ko'rsatadi.

Human qismi Odam uchun.

Dataning kelib chiqishi tarixi, litsenziya shartlari bajarilgani, haqidagi bayonot