Sunbae — LLM training data design

Task 1: LLM domain

My LLM	**Sunbae** (선배, "katta kursdosh") — Koreyadagi o'zbek talabalari uchun o'zbek tilida ishlaydigan kundalik hayot yordamchisi
Main purpose	Koreyada o'qiyotgan talabalarga uy-joy, viza va hujjatlar, qisman ish, sog'liq sug'urtasi, bank va transport bo'yicha savollarga o'zbek tilida javob beradi va rasmiy manbalarga yo'naltiradi
Target users	Koreyadagi o'zbek talabalari: universitet va til kursi talabalari, ayniqsa Koreyaga endi kelgan birinchi yil talabalari

Task 2: Data manbalari

1–3-manbalar modelga o'zbek tilini o'rgatadi, 4–6-manbalar Koreyadagi talaba hayoti haqidagi bilimni beradi.

#	Dataset Name	Domain	Source URL	Why need it?
1	FineWeb-2 (o'zbekcha qismi, `uzn_Latn`)	Umumiy veb matn	HuggingFaceFW/fineweb-2	O'zbek tilida ravon gapirish uchun asosiy til datasi
2	uz-wiki (o'zbekcha Vikipediya)	Ensiklopediya	yakhyo/uz-wiki	Aniq faktlar va to'g'ri adabiy o'zbek tili
3	Uzbek news dataset	Yangiliklar	MLDataScientist/Uzbek_news_dataset	Rasmiy va zamonaviy o'zbek tili
4	Study in Korea: Life in Korea	Talaba hayoti (hukumat sayti)	studyinkorea.go.kr	Xalqaro talabalar uchun rasmiy ma'lumot: uy-joy, sug'urta, kundalik hayot
5	GNU Global (Gyeongsang National University)	Universitet: viza, yotoqxona	gnu.ac.kr/global	Davlat universitetining xalqaro talabalar uchun qoidalari
6	SMIT (sobiq KGIT): International Affairs Center	Universitet: viza, sug'urta, talaba hayoti	iac.smit.ac.kr	Xususiy institut qoidalari,

Task 3: Data sifatini baholash

O'zbek tili manbalari katta va xilma-xil, lekin Sunbae ga kam tegishli; Koreya hayoti manbalari esa tegishli, lekin kichik va bir xil.

#	Dataset	Relevance	Quality	Diversity	Safety	Deduplication	PII
1	FineWeb-2 (uz)	✓ Med	✓ Med	✓ High	✗ Med	✓ High	✗ Med
2	uz-wiki	✓ Med	✓ High	✓ Med	✓ High	✓ Med	✓ High
3	Uzbek news	✓ Med	✓ Med	✓ Med	✓ Med	✗ Low	✗ Med
4	Study in Korea	✓ High	✓ Med	✗ Low	✓ High	✓ Med	✓ High
5	GNU Global	✓ Med	✓ Med	✗ Low	✓ High	✓ Med	✓ Med
6	SMIT (KGIT)	✓ Med	✓ Med	✗ Low	✓ High	✓ Med	✓ High

Baholarning sabablari:

1. **FineWeb-2:** o'zbek tili uchun foydali, Koreya haqida deyarli yo'q; filtrlangan, lekin veb matnda reklama, zararli kontent va shaxsiy ma'lumotlar qolishi mumkin; takrorlar yaratuvchilar tomonidan olib tashlangan.
2. **uz-wiki:** muharrirlar tekshirgan ensiklopedik matn; mavzular xilma-xil, lekin uslub bitta; bot yaratgan shablon maqolalar o'xshash bo'lishi mumkin; asosan ommaviy shaxslar haqida.
3. **Uzbek news:** jurnalistlar yozgan, lekin scraping qoldiqlari bor; bir xil xabar ko'p saytlarda takrorlanadi; oddiy odamlarning ismlari va manzillari uchraydi.
4. **Study in Korea:** eng tegishli manba; ma'lumot ishonchli, lekin scrape, tozalash va tarjima kerak; sahifalar kam.
5. **GNU Global:** qoidalar faqat bitta universitetga tegishli; e'lonlarda xodimlar va talabalarning ma'lumotlari bo'lishi mumkin.
6. **SMIT:** International Affairs Center sahifalarida viza, chet ellik ro'yxatdan o'tishi, sug'urta va talaba hayoti haqida ma'lumot bor, lekin qoidalar faqat bitta institutga tegishli va sahifalar kam; matn koreys va ingliz tilida (o'zbekcha faqat avtomatik tarjima menyusi orqali).

Task 4: Litsenziya

Faqat 1–3-manbalarning litsenziyasi ochiq; Sunbae uchun eng kerakli 4–6-manbalar "All rights reserved".

#	Dataset	Commercial	Modification	Redistribution	Additional requirements
1	FineWeb-2 (uz)	Yes	Yes	Yes	ODC-By 1.0: Attribution. Qo'shimcha: Common Crawl Terms of Use; asl saytlarning huquqlari mualliflarida qoladi
2	uz-wiki	Yes	Yes	Yes	Datasetda MIT, lekin asl manba Vikipediya: CC BY-SA 4.0 (Attribution + ShareAlike)

#	Dataset	Commercial	Modification	Redistribution	Additional requirements
3	Uzbek news	Yes	Yes	Yes	CC BY 4.0: Attribution + o'zgarishlarni qayd etish. Asl saytlarning ruxsati noma'lum (Task 5)
4	Study in Korea	No	No	No	© NIIED. All rights reserved. NIIED ning yozma ruxsati kerak
5	GNU Global	No	No	No	© 2025 Gyeongsang National University. All rights reserved
6	SMIT (KGIT)	No	No	No	Copyright © 2022 SMIT International Affairs Center. All Rights Reserved. Ruxsat uchun: admission@smit.ac.kr

Task 5: Data provenance

Dataset yaratuvchisi yozgan litsenziya asl mualliflarning huquqlarini bekor qila olmaydi, shuning uchun har bir zanjir asl manbagacha tekshirildi.

#	Dataset	Yaratuvchi	Asl manba	Asl mualliflar	Zanjir	Huquqiy xavf
1	FineWeb-2 (uz)	Hugging Face	Common Crawl (96 ta snapshot, 2013–2024) → veb sahifalar	Sayt egalari	✓ Aniq	Med
2	uz-wiki	yakhyo	O'zbekcha Vikipediya (2024-09-20 holati)	Ko'ngilli muharrirlar	✓ Aniq	Low–Med (MIT ≠ CC BY-SA)
3	Uzbek news	MLDataScientist	O'zbekcha yangilik saytlari (ro'yxati berilmagan)	Jurnalistlar, nashriyotlar	✗ Noaniq	Med–High
4	Study in Korea	— (to'g'ridan-to'g'ri)	studyinkorea.go.kr	NIIED	✓ Aniq	High (All rights reserved)
5	GNU Global	— (to'g'ridan-to'g'ri)	gnu.ac.kr	GNU	✓ Aniq	High (All rights reserved)
6	SMIT (KGIT)	— (to'g'ridan-to'g'ri)	iac.smit.ac.kr	SMIT International Affairs Center	✓ Aniq	High (All rights reserved)

Asosiy topilmalar:

- **uz-wiki:** yakhyo datasetni MIT deb belgilagan, lekin Vikipediya matni CC BY-SA 4.0. Haqiqiy litsenziya — CC BY-SA 4.0.
- **Uzbek news:** dataset CC BY 4.0, lekin maqolalar qaysi saytlardan scrape qilingani va nashriyotlar ruxsat bergani noma'lum.

Task 6: Data mixture

Mixture ning 65% qismi o'zbek tili, 35% qismi Koreyadagi talaba hayoti.

Manba	Ulush	Sabab
FineWeb-2 (uz)	35%	Eng katta va xilma-xil: o'zbek tilining asosi
uz-wiki	20%	Sifati yuqori
Uzbek news	10%	Rasmiy til, lekin takrorlar va litsenziya xavfi bor
Koreya hayoti: o'zimiz yaratgan savol-javoblar	30%	Asosiy vazifa: rasmiy faktlar asosida, o'z so'zlarimiz bilan yozilgan
Study in Korea, GNU, SMIT	5%	Faqat ruxsat olingandan keyin; ungacha 0% va bu ulush o'zimiz yaratgan dataga qo'shiladi
Jami	**100%**	

Why this mixture? Sunbae o'zbek tilida ravon gapirishi uchun mixture ning 65% qismi o'zbekcha matnlardan iborat. Bunda sifati yuqori bo'lgan uz-wiki ga kattaroq ulush berildi. Koreyadagi talaba hayoti modelning asosiy vazifasi bo'lgani uchun 35% shu mavzuga ajratildi. Rasmiy saytlar "All rights reserved" bo'lgani sababli, bu data ularning faktlari asosida o'zimiz yozgan savol-javoblardan tuziladi va saytlarning matni faqat ruxsat olingandan keyin qo'shiladi.

Task 7: Yakuniy qaror

2 ta manba ishlatiladi, 1 tasi qo'shimcha tekshiruvga qoldiriladi, 3 tasi ruxsat olinmaguncha ishlatilmaydi.

Dataset	Decision	Reason
A. FineWeb-2 (uz)	Use	Litsenziya aniq va ruxsat beruvchi (ODC-By), data katta va xilma-xil. Shart: PII va zararli kontentni qo'shimcha filtrlash, Attribution
B. uz-wiki	Use	Sifati yuqori. MIT emas, asl CC BY-SA 4.0 shartlari bilan: Vikipediyani ko'rsatish, ShareAlike
C. Uzbek news	Needs further review	Asl saytlar ko'rsatilmagan, nashriyotlarning ruxsati noma'lum; takrorlar va PII ko'p. Saytlar aniqlanmaguncha faqat 10%
D. Study in Korea	Do not use (ruxsat olinguncha)	Relevance yuqori, lekin © NIIED. All rights reserved. Ungacha faqat javoblarda havola sifatida
E. GNU Global	Do not use (ruxsat olinguncha)	All rights reserved; qoidalar faqat bitta universitetga tegishli
F. SMIT (KGIT)	Do not use (ruxsat olinguncha)	Viza, sug'urta va talaba hayoti haqida ma'lumot bor (relevance Med), lekin All Rights Reserved va qoidalar faqat bitta institutga tegishli. SMIT dan ruxsat so'raladi