Pre-training & Data: 30 ta savol

3-dars · Interview Questions · Mening javoblarim

Basic (1–10)

Savol 1. Pre-training va post-training farqi nima? Har bir bosqichda modelda nima o'zgaradi? Qaysi biri ko'proq data talab qiladi?

MENING JAVOBIM

Pre-trining => modelga next token prediction qila oladigan bilim berish. Katta data shu bosqichda talab qilinadi.
Post-training => Moslashtirish. tarbiya, odobli qilish desak ham boladi. RLHF, SFT lar bilan

Savol 2. Common Crawl'ni to'g'ridan-to'g'ri training uchun ishlatib bo'lmaydi. Nega?

MENING JAVOBIM

Chunki Common crawldagi datalar internetdagi juda ha kop web saytlardan scrape qilingan datalar. Tabiiyki ularda HTML taglar, Reklamalar, Duplicate bolgan datalar ham boladi. Common crawlning filterlangan varianti - FineWeb.

Savol 3. FineWeb nima va u Common Crawl'dan qanday olingan?

MENING JAVOBIM

FineWeb Commoncrawlning Filterlangan versiyasi

Savol 4. LLM loyihasida .gitignore ichida nima bo'lishi kerak va nega?

MENING JAVOBIM

1. Data - chunki datalsrimiz juda ham katta hajmda bo'ladi.
2. Weights - chunki asosiy boyligimiz desak ham boladi. manashu weights ni olish uchun juda ham kata cost sarflangan boladi
3. API keys, password shunday privste bolgan malumotlar

Savol 5. API kalit yoki token repository'ga tushib qolsa nima qilasiz?

MENING JAVOBIM

1. Darhol uni gitignorega qoshish kerak va cachedan tozalab qayta push qilish kerak.
2. Chiqi ketgan privatelarni almashtirish kerak

Savol 6. **Pre-training uchun nega CPU emas, GPU ishlatiladi? Nima uchun LLM da GPU kerak? Nima uchun VS Code + Google Colab?**

MENING JAVOBIM

Pre trainingda asosiy bilim beriladi bu degani judam katta hajmadgi datani oqitish kerak degani. GPU da yadrolar minglab bor va ular parallel ishlaydi va tez CPU da esa kam sonli 4 - 64. LLM da hisob kitoblar ko'p bo'lgani uchun GPU kerak. VS code + google colab => googlecolabning CPU, GPU, TPU sidan foydalaishimiz mumkin ozimizning VS code orqali. Hamma kodlar colabning serverida run boladi, Biz faqatgi vscode interfacedan foydalanamiz xols

Savol 7. **Data mixture nima va nega bitta dataset yetarli emas?**

MENING JAVOBIM

Masalan Men Sunbae loyihamni oladigan bolsak, Menga O'zbek tili uchun va Koreyadagi hayot uchun malumotlar kerak. Data sourcelarning relevance, Quality, Quantity, Safety, License va hokazo lariga qarab eng yaxshilaridan nisbatan foizi koproq holatda olamiz. Yani Asosiy focusimiz Tlabalarga kundalik hayotda yordam berish bolgandan keyin, Albatta Koreyada chet elliklar uchun qollanmalar bolgan data sourcelardan kattaroq foizda olamiz va hokazo

Savol 8. **Deduplication nima va nega training'dan oldin qilinadi?**

MENING JAVOBIM

Deduplication - Takroriy matnlarni tashlab yuborish 1 tasini olib qoladi. Agar uni tashlab yubormasdan train qilinsa memorization bolib qoladi. Model yodlab oladi

Savol 9. **Nega ko'proq data avtomatik ravishda yaxshiroq modelni anglatmaydi?**

MENING JAVOBIM

chunki ko'p datani boshqarish qiyinroq. filterlash, deduplication qilish vahokazo. Agar datamiz kam bo'lsa uni sifatini yaxshilashimiz ancha onson va bu holatda modelimiz aniqroq javob beradi. Yana juda ham kop data bilan oversampling ham bolib qolishi mumkin

Savol 10. **MIT litsenziyali dataset ustida model o'rgatsangiz, sizdan nima talab qilinadi?**

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> MIT juda erkin litsenziya: tijoriy foydalanish, o'zgartirish va tarqatish mumkin. Yagona shart — asl copyright yozuvi va litsenziya matnini saqlash. Amalda datasetni model card da ko'rsatiladi va asl copyright yozuvi "Licensing Notice" bo'limida keltiriladi.

Intermediate (11–20)

Savol 11. **Coding'ga yo'naltirilgan LLM uchun data mixture tuzing va har bir foizni asoslang.**

MENING JAVOBIM

1. Asosiy maqsad coding bolgani uchun - coding data sourcelarga 60 %
2. O'zbek tilida javob kerak bo'lsa - o'zbek tilini o'rgaish uchun - 20 %
3. Matematika ham kerak boladi - bunga ham 20 %

Savol 12. **Compute sarflashdan oldin korpus sifatini qanday o'lchaysiz?**

MENING JAVOBIM

Relevant, QUality, SAfety, PII, License, diversity, accuracy

Savol 13. **Qattiq filtratsiya va data hajmini saqlash o'rtasidagi trade-off nimada?**

MENING JAVOBIM

Juda qattiq filterlansa - Data hajmi kamayib ketadi, Muhim patternlar ham yoqoladi
Juda yumshoq qilinsa - Data quality pas bolib qoladi, Lekin data hajmi nisbatan koproq boladi,

Savol 14. **Web korpusda benchmark leakage (test contamination) ni qanday aniqlaysiz?**

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> Contamination — benchmark (test) savollarining o'qitish datasiga tushib qolishi; model javobni yodlab oladi va natija yolg'on yuqori chiqadi. Aniqlash: korpusni test savollari bilan n-gram (masalan, 13 so'z) moslik orqali solishtirish, embedding o'xshashligi, canary stringlar va modelga savol boshini berib, davomini so'zma-so'z yozishini tekshirish. Topilgan hujjatlar olib tashlanadi.

Savol 15. **Exact va fuzzy (MinHash/LSH) dedup — qachon qaysi biri?**

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> Exact dedup — hash orqali aynan bir xil matnlarni topadi: tez va arzon, lekin 1 harf farqni ham boshqa matn deb hisoblaydi. Fuzzy dedup (MinHash + LSH) — deyarli bir xil matnlarni (sana yoki reklama farq qiladigan) topadi, lekin qimmatroq. Amalda avval exact, keyin fuzzy.

Savol 16. Datasetning 80% ingliz tilida, mahsulot esa o'zbek tilidagi foydalanuvchilar uchun. Nima qilasiz?

MENING JAVOBIM

Mavjud barcha o'zbek tilidagi datasetni olamiz qolganiga iloji yoq ingliz tilidagi datani olamiz. Tokenizationda - o'zbek tilidagi sozlar tokeni koproq boladi ingliz tilidagi ga nisbatan. masalan 1 ta token 0.75 sozga teng taxminan ingliz tilida. bu korsatkich ozbek tilida ko'proq. Ko'proq token - ko'proq data

Savol 17. Qanday safety va PII filtratsiyasini qo'llaysiz va overfiltering xavfi nimada? .gitignore xavfsizlik mexanizmimi? Nega?

MENING JAVOBIM

Zararli kontentlarni olib tashlaymiz masalan haqoratli so'zlar, zo'ravonlikka oid bo'lganlaini. PII filteri Personaly Indentifable Indicator - Shaxslarning ismlari, email, telefon raqamlari, passwordlar ni filter qilish. butunlay olib tashlanadi, maskalanishi mumkin. Bitta default shaxsning ism, email .... dan foydalaniladi. Judaham qattiq filterlab yuborasak Haqoratlarni taniy olmaydi yani input qilib kirgizilganda bu haqoratligini bilishi kerak yoki sahxsiy malumotlarni contextlarini taniy olmay qoladi. .gitignore - API keys, passwords, DAta, Venv ... larni yani privacy malumotlarni va Katta hajmli malumotlarni githubga push qilmaydi

Savol 18. Pre-training data va post-training (SFT/preference) data qanday farq qiladi?

MENING JAVOBIM

Pretraining data - ko'p, Next tokenini predict qilish ni biladi xolos, Narxi juda ham yuqori
Posttraining - data kam, SFT, RLHF lar bilan savolga javob berishni, odob, tarbiyani orgatamiz sifatli, Narxi kamroq

Savol 19. Repo'da 200 GB data va 40 GB checkpoint bor. Buni Git'siz qanday versiyalaysiz?

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> Katta fayllar Git da saqlanmaydi. DVC: Git da faqat kichik .dvc fayl (hash) turadi, data esa S3/GCS da. Checkpoint lar Hugging Face Hub da. Har bir run uchun W&B/MLflow da kod commit + data versiyasi + checkpoint + config bog'lanadi.

Savol 20. Dataset CC-BY-NC litsenziyasida. Uni commercial modelda ishlata olasizmi?

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> Yo'q. NC = NonCommercial, ya'ni tijoriy maqsadda ishlatish taqiqlangan. Yechim: muallifdan tijoriy ruxsat olish, ruxsat beruvchi muqobil dataset topish yoki faqat tadqiqot modelida ishlatish. Har bir datasetning litsenziyasini lineage da yozib borish kerak.

Advanced (21–30)

Savol 21. Compute budget qat'iy. Uni ko'proq data va ko'proq parametr o'rtasida qanday taqsimlaysiz?

MENING JAVOBIM

Birinchi parameterlar sonini aniqlaymiz N = 12 L d**2
L - Layerlar soni
d - token embeddings dimension

Tokenlar soni = > chinchilla - D = 20N

Budgetga mos token dimension, layerlar soni shularni kombinatsiya qilib hisoblab compute budgetga moslaymiz

Savol 22. Common Crawl WARC'dan training-ready shard'gacha bo'lgan pipeline'ni bosqichma-bosqich tasvirlang.

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> WARC (xom HTML) → URL filtr → matnni ajratish → til aniqlash → sifat filtrlari → dedup → safety → PII → decontamination → normalization → mixture → tokenization → packing (bir xil uzunlik) → shuffle + shard → manifest va versiyalash.

Savol 23. Mixture og'irliklarini intuitsiya emas, empirik tarzda qanday tanlaysiz?

MENING JAVOBIM

Random tanlamayman. Asosiy maqsaddan kelib chiqqan holda tanlanadi.

Data sidatlaridan kelib chiqib yani data o'lchovlaridan
Relevant, Quality, Safety, Accuracy, License shularga qarab ularga berilgan ballar boyicha tanlanadi

Savol 24. Unique token tugasa, datani takrorlash (multi-epoch) nimaga olib keladi?

MENING JAVOBIM

Datani takrorlash chegarasi 2-4, unda oshib ketsa datani yodlab oladi. Overfitting

Savol 25. Quality classifier "Wikipedia-ga o'xshash" matnni afzal ko'rsa, korpusda nima yo'qoladi?

MENING JAVOBIM

Vikipediada bilimi boyicha o'rganib qoladi model. Modelda diversity yoq bolib oladi

Savol 26. Metrika o'sishiga aynan data o'zgarishi sabab bo'lganini qanday isbotlaysiz?

MENING JAVOBIM

bilmayman

QISQACHA MA'LUMOT

> Nazoratli tajriba: control (eski data) va treatment (yangi data) run lari, faqat data farq qiladi — model, sozlamalar, token soni va eval bir xil. Bir necha random seed bilan tekshiriladi: yaxshilanish seed tebranishidan katta bo'lishi kerak. Contamination yo'qligi ham tasdiqlanadi.

Savol 27. Model training matnini so'zma-so'z qaytarmoqda. Sabab, aniqlash va data darajasidagi yechim?

MENING JAVOBIM

Deduplication filter yaxshi qilinmagan yoki Data yetishmaganda datani 2-4 epoch takrorlanishidan oshirib yuborilgan. Yechim: Deduplication qilish - balkim chuqurroq, 2-4 epoch

Savol 28. Ochiq relizga tayyorlanayotgan model uchun audit qilinadigan data provenance qanday quriladi?

MENING JAVOBIM

Listenziyalar yoziladi. Litsenziyadagi shartlar boyicha yoziladi.
Masalan: data owneri, qayerdan olinganligi linklar bilan.
Yaml filega => kompyuter uchun.
Human uchun => odam oqib tushunishi uchun

Savol 29. Training davomida data mixture'ni o'zgartirasizmi? Mexanizmi bilan asoslang.

MENING JAVOBIM

Validation bilan testing qilinayotgan natija yaxshi bolmasa qaysidir data turiga tortib ketsa bias bolib qolsa o'zgartirish mumkin

Savol 30. Data tozalashni to'xtatib, training'ni boshlash vaqtini qanday belgilaysiz?

MENING JAVOBIM

Filteringning har bir bosqichini o'ta chuqur filtering qilmasdan va o'ta sayoz ham qilmasdan o'rta darajada qilish