Downloading dataset

- Datani yuklab olgandan song datani saqlash, tozalash va natijani saqlash qismlarini bajaramiz.

=> Datani data/raw/ papkaga saqlaymiz.
-format .jsonl (har bir qator = bitta hujjat)
json list

=> Tozalashdan oldin datani ko'rib chiqish kerak. Datada qanday muammolar mavjudligini bilish uchun.

HTML remover

=> Matndan HTML teglarni olib tashlaydi.

HTML Entity Decoding

=> HTML dagi ~~entity~~ kodlarni oddiy belgilarga aylantiradi.
- 'web sahifalarda ba'zi belgilar kod sifatida saqlanadi'

Unicode NFKC normalization

=> ko'rinishi bir xil, lekin kompyuter kodi xar xil bo'lgan belgilarni bitta standart shaklga keltiradi.

Whitespace normalization

=> ortiqcha probellar, teglar va bo'sh qatorlarni tozalaydi.

Control character removal

=> ko'rinmaydigan "boshqaruv" belgilarni o'chiradi

Empty-document removal

=> tozalashdan keyin bo'sh bo'lgan hujjatlarni olib tashlaydi.

HTML removal → Entity decoding → NFKC → Control character removal → whitespace → Empty doc re...

Filtering

Har bir data sifat qoidalari bo'yicha tekshiriladi. Mos kelmaganni olib tashlaymiz.

min-chars threshold beramiz. yani

=> threshold = 200 minimal belgilar soni 200 ta bo'lishikerak bundan kam belgi bo'lsa ularni tashlab yuboramiz.

min-alpha-ratio.

=> Bizga matn kerak. Matndan iborat ragamlar jadvallardan tashkil topgan-larini olib tashlaymiz.

- masalan ratio = 0.3 30% dan kop bo'lishi kerak harflar nisbati.

max_repeated_line

Takroriy qatorlar. ratio = 0.3 -> 30% > qatorlar takrorlangan bo'lsa olib tashlaymiz

Exact deduplicator

=> Har bir matn uchun hash hisoblanadi va bir xil hashga ega matnlarning faqat birinchi nusxasi qoldiriladi.

=> Matn kichik harflarga o'tkaziladi va barcha bo'sh joylar bitta probelga keltiriladi. Keyin SHA-256 hash hisoblanadi.

1. Matnni baytlarga aylantiriladi. Hash baytlar bilan ishlaydi
   .encode('utf-8')
2. .hexdigest() - natijani o'qiladigan 64 belgilik matn ko'rinishida qaytaradi

Hashlar set da saqlanadi.

PII

=> Shaxsiy ma'lumotlar regex shablonlari bilan topiladi va maxsus teglarga almashtiriladi.

[asad@gmail.com <=> <Email>]